

-->

28页PPT详解腾讯数据挖掘体系及应用

2017-05-25 彭远权 [大数据](#) 大数据

小提示

点击上方蓝色字体即可一键关注哦~

导读

本文主要是腾讯 高级数据分析师 彭远权详解腾讯 数据挖掘体系 及应用，28页PPT的阐述了：数据工作是做什么的？数据理念和原则、数据体系架构、数据实战中DBScan算法在LBS上的应用等等。

腾讯数据挖掘体系&应用

——彭远权
腾讯高级数据分析师

引子

数据工作是做什么的？

产 品：为用户做某种事情提供便利的平台

数据工作：记录用户和其他物品在不同时间、空间上
发生事件的事实并研究其规律

数据工作内容



数据能力

Excel	★★☆☆☆	大数据平台	★★☆☆☆	行业眼光	★★★★☆
数据库	★★★★☆	数据挖掘原理	★★★★☆	知识理论	★★★★☆
编程能力	★★★★☆	数据挖掘库	★★★★☆	架构能力	★★★★★
统计学基础	★★★★☆	算法实现能力	★★★★☆		
青铜级		白银级		钻石级	

上篇：数据理念

--数据体系建设方法论

数据原则



数据原则-完整性

- 主体完整性
- 主体属性完整性
- 记录完整性



数据原则-一致性

- 协议一致性



- 数据结构一致性

name|age|score VS name|score|age|foodid

- 单位&数据类型一致性

1447345312 VS 1447143317474

数据原则-节约性


张三|food1
张三| food1
李四| food2

次数类指标虚假 & 耗费计算资源去重


数据原则-异常处理

- ◆默认值约定 默认为0 vs 上报空值
- ◆特殊字符处理 Base64好用吗？
- ◆长度范围规范 数据完整性隐患
- ◆值域范围规范 数据一致性隐患

日志六要素



数据体系架构



下篇：数据实战

--DBScan算法在LBS上的应用

WiFi群落识别数据可视化



楼宇识别

不规则形状群落聚类

什么是DBSCAN ?

Density-Based Spatial Clustering of Applications with Noise
基于密度的聚类算法，能够把具有**足够高密度**的区域划分为簇。

DBSCAN算法优点



算法思想 - 假设


邻域：给定对象半径 r 内的邻域称为该对象的 r 邻域；
核心对象：如果对象的 r 邻域至少包含最小数目 $MinPts$ 的对象，则称该对象为核心对象；
密度可达：给定一个对象集合 D ($p \in D, q \in D$)。如果 p 在 q 的 r 邻域内，并且 q 是一个核心对象，则我们说对象 p 从对象 q 出发是直接密度可达的；

密度可达传递性


- 如果存在一个对象链 $p_1, p_2, p_3, \dots, p_n, p_1=q, p_n=p$, 对于 $D, i \in 1 \sim n$, $p_{(i+1)}$ 是从 p_i 关于 r 和 MinPts 直接密度可达的, 则对象 p 是从对象 q 关于 r 和 MinPts 密度可达的;
- 如果存在对象 o 属于 D , 使对象 p 和 q 都是从 o 关于 r 和 MinPts 密度可达的, 那么对于对象 p 到 q 是关于 r 和 MinPts 密度相连的;
- 密度可达是直接密度可达的传递闭包, 这种关系非对称, 只有核心对象之间相互密度可达; 密度相连是一种对称的关系;

密度可达传递性


MinPts=3




实现思路




和kmeans对比



其他场景



遇到的问题？



时间复杂度
 $O(m^2)$
单机计算瓶颈

DBSCAN算法的时间复杂度？ $O(m^2)$



5500+Point 时间消耗 15分钟

WiFi数：2亿+



测试数据4w 耗时近1小时
全量数据：8亿+

DBSCAN大数据瓶颈突破




分块带来的边界问题

GeoHash



分块实现

优化效果



分块边界联通性考虑

29GB 数据 8亿+数据 80W+群落 8分钟

154 Map 600 Reduce

近期精彩活动（[直接点击查看](#)）：

[福利](#) · [阅读](#) | [免费申请读大数据新书 第19期](#)

END

版权声明：

转载文章均来自公开网络，仅供学习使用，不会用于任何商业用途，如果出处有误或侵犯到原作者权益，请与我们联系删除或授权事宜，联系邮箱：holly0801@163.com。转载大数据公众号文章请注明原文链接和作者，否则产生的任何版权纠纷与大数据无关。

大数据

为大家提供与大数据相关的最新技术和资讯。



[长按指纹](#) > [识别图中二维码](#) > [添加关注](#)

近期精彩文章（[直接点击查看](#)）：

161224 [2016年“大数据”产业的“真实面目”](#)

- 161222 [傅盛：深度学习是一种新的思维方式](#)
- 161216 [CCF：2017年大数据发展趋势报告及解读](#)
- 161213 [一文看懂人工智能：原理，技术和未来](#)
- 161208 [如何七周成为数据分析师](#)
- 161206 [一篇文看懂Hadoop：风雨十年，未来何去何从](#)
- 161205 [2017年大数据的十大发展趋势](#)
- 161129 [大数据等最核心的关键技术：32个算法](#)
- 161126 [2016十大热门大数据岗位，拿走不谢](#)
- 161122 [2017年关于数据科学六大预言](#)
- 161119 [漫画：什么是机器学习？](#)
- 161114 [终年32岁的传奇数学家，生前寂寂无闻，一个世纪后却让硅谷领袖们集体落泪致敬](#)
- 161112 [如何用大数据思维找女朋友？](#)
- 161108 [漫画：什么是大数据](#)
- 161107 [数据可视化的七大秘密](#)
- 161105 [Gartner公布2017年十大战略科技发展趋势](#)
- 161028 [经验贴 | 怎样进行大数据入门级学习](#)
- 161025 [干货：数据分析师的能力和工具体系](#)
- 161023 [不装逼地说, 在Google十年, 到底学到啥？](#)
- 161016 [大数据投资人必读：中国大数据发展与投资分析报告](#)
- 161014 [您的位置信息如何被利用？——基于位置信息的应用和地理信息匹配算法](#)
- 161009 [硅谷教父凯文·凯利最新预言：未来20年最重要的2个科技趋势！](#)
- 161001 [十张图看懂未来的大数据世界](#)

更多精彩文章，请在公众号后台回复000查看，谢谢。