

30页PPT探索大数据时代风控模型技术和应用！

2017-12-21 [数果大数据](#)

大数据时代风控模型技术的探索和实践



-  **大数据概述**
-  **大数据风控模型技术**
-  **大数据风控技术应用**
-  **展望**

目录 CONTENTS

 数据观

01 *Part One*

大数据概述



数据观

01. 什么是大数据



大数据的特征归纳为 4 个 “V”（量 Volume，多样 Variety，价值 Value，速 Velocity），或者说特点有四个层面

- 数据体量巨大
- 数据类型繁多
- 价值密度低，商业价值高
- 处理速度快

从大数据的价值链条来分析，存在三种模式

- 有大数据，但是没有利用好
- 没有数据，但是知道如何帮劣有数据的人利用它
- 既有数据，又有大数据思维

数据观

02. 大数据技术



- 对碎片化数据的整合能力

这种对大数据的理解特别适用于征信业

- 搜集更多的数据维度


相比于传统征信数据的强相关性，这些大数据征信的数据和消费者的信用状况相关性较弱

- 实现信用信息的有力补充

大数据存在稀疏性，大数据技术可以探寻数据稀疏的原因，进而可以获取一些有用的消费者信用信息

数据观

- 大数据开打在“大”，而在于“有用”，价值含量、挖掘成本比数量更为重要
 - 大数据研究的最终目的是形成决策模式
- 大数据价值挖掘：优秀的算法，开源的工具包
 - 1. 描述性分析：面向过去，发现潜藏在数据表面之下的历史规律或模式
 - 2. 预测性分析：面向未来，对未来趋势进行预测
- 大数据的价值体现更强调相关性
 - 弱化因果性



2. 大数据风控模型技术

- 01 传统风控模型
- 02 基于机器学习算法的风控模型探索应用
- 03 风控模型发展规划与应用

发展背景

信用评分模型技术的发展，是与消费信贷产业的繁荣、数据库技术的发展、数理统计模型技术的进步、计算机技术的飞跃、社会征信体系的完善等密切相关的

► 政策环境

宏观与微观共同作用的结果，使消费信贷产业繁荣发展；
风险与回报相对应的客户规律，信用风险管理成为核心

► 科技基础


数据库技术：数据大规模的收集、整理、保存、提取；
数理统计模型：知识发现、数据挖掘
计算机技术：数据分析、模型发展、模型自动化部署，使应用更加简单

► 数据基础，欧美社会征信体系的形成和健全

三大征信局
健全的信用法律制度和监管机构

数据观

建模流程



优势

运用先进的数理统计分析来开发评分模型作为决策的依据，具备如下优势

- 客观性
- 一致性
- 效率性
- 准确性
- 全面性

数据观

最重要的应用领域之一是信用卡的生命周期管理。信用卡业务具备发展和应用信用评分模型的两个特征：

- ▶ 数据量庞大，使开发评分模型成为可能
- ▶ 业务量大，使批量化、自动化的管理成为必要



数据观

02.基于机器学习算法的风控模型探索应用

数据观

发展背景

数据基础与技术基础

- ▶ 数据维度更广
电商数据、运营商数据、社交网络数据和搜索引擎数据等
- ▶ 计算机处理能力的显著提高
- ▶ 开源的算法包
Python, R等，大大节省了算法实现成本

应用机器学习算法的必然性

- ▶ 大数据的稀疏性
大数据的显著特征之一，即缺失率高，影响变量的有效性和模型的稳定性
- ▶ 大数据更多是弱变量
基于传统的逻辑回归算法容易欠拟合，建模效果不佳，无法应用
- ▶ 传统的逻辑回归算法对数据要求较高

数据观

SVM支持向量机


原理

SVM从线性可分情况下的最优分类面发展而来

最优分类面就是要求分类线不但能将两类正确分开(训练错误率为0),且使分类间隔最大

SVM考虑寻找一个满足分类要求的超平面,并且使训练集中的点距离分类面尽可能的远,也就是寻找一个分类面使它两侧的空白区域(margin)最大

过两类样本中离分类面最近的点且平行于最优分类面的超平面上 H_1, H_2 的训练样本就叫做支持向量



优势

支持向量机是数据挖掘中的一项新技术,是借助于最优化方法来解决机器学习问题的新工具,开始成为克服过学习问题的强有力手段。它在解决小样本、非线性及高维模式识别中表现出许多优势,并能够推广应用到函数拟合等其他机器学习问题中

数据观

SVM支持向量机

实践

核函数的选择

对原始特征进行变换,提高原始特征维度,解决支持向量机模型线性不可分问题,进而提高模型预测精度

不会比线性条件下增加多少额外的计算量

不同的核函数可能会带来不同的结果,一般是需要尝试来得到的,识别率更高、性能更好的核函数是径向基核函数,也称高斯核函数

高斯核甚至是将原始空间映射为无穷维空间,因此增加维度可以区分任意两个相似的事物

惩罚系数

表示对分错的点加入多少的惩罚

在线性可分的情况下不需要考虑惩罚系数

由用户去指定,当C很大的时候,分错的点就会更少,但是过拟合的情况可能会比较严重,当C很小的时候,分错的点可能会很多,不过可能由此得到的模型也会不太正确

不容易过拟合

调整惩罚系数

最优化函数更平滑

数据观

随机森林

基本思想

通过自助法(boot-strap)重采样技术,特征选择采用随机的方法去分裂每一个节点,然后根据自助样本集生成k个决策树组成的随机森林,新数据的分类结果采用简单多数投票法。

单棵决策树的分类能力可能很小,但在随机产生大量的决策树后,一个测试样本可以通过每一棵树的分类结果经统计后选择最可能的分类。

优势

对缺失数据和非平衡的数据比较稳健

它能够处理很高维度(feature很多)的数据,并且不用做特征选择

在训练完后,它能够给出哪些feature比较重要

训练速度快

实现比较简单

数据观

随机森林

实践

► 分类性能的主要因素

森林中单棵树的分类精度

森林中树之间的相关性

► 两个重要参数

树节点预选的变量个数

树的个数

► 特征选择

可以作为EDA的一部分

► 容易过拟合

特别是在数据集相对小的时候

特征选择可以减轻过拟合现象



集成学习

集成学习是近年来机器学习领域中的研究热点之一。经典的两个集成算法是Bagging和AdaBoost，它们分别以某种巧妙的方式将若干基分类器的预测结果进行综合，以达到显著提升分类效果的目的

► Bagging算法

通过bootstrap抽样得到若干不同的数据集，以这些数据集分别建立模型，即得到一系列基分类器，这些分类器由于来自不同的训练样本，它们对同一测试集的预测效果不一。因此，Bagging算法随后对基分类器的一系列预测结果进行投票，从而得到每一个测试集样本的最终预测结果，这一集成后的结果往往是准确而稳定的




集成学习

► AdaBoost(Adaptive Boosting)算法


实时调节权重的过程正是AdaBoost算法的优势所在，它通过将若干具有互补性质的基分类器集合于一体，显著提高了集成分类器的稳定性和准确性

► GBDT(Gradient Boost Decision Tree)算法

Gradient Boost与传统的Boost的区别是，每一次的计算是为了减少上一次的残差(residual)，而为了消除残差，我们可以在残差减少的梯度(Gradient)方向上建立一个新的模型




AdaBoost算法



集成学习

实践


GBDT算法在不同变量数测试集上的模型效果



集成学习

实践

GBDT算法在不同变量数的训练集与测试集上的模型效果



算法比较

基于用户行为数据，分别运用传统的逻辑回归算法、SVM算法、随机森林算法得到的模型效果如下：K-S值是区分能力指标

传统的逻辑回归算法：




特征选择
变量分解
变量的可解释性

随机森林算法：

变量个数
节点分裂选择的变量个数
树的个数

SVM算法：

核函数的选择
是否归一化
参数调整 Cost, Gamma



数据观

03.风控模型发展规划与应用

数据观

发展规划与应用

发展规划


- 基于传统的逻辑回归算法(更加注重模型解释性)
- 基于机器学习算法(黑箱模型)
 - SVM算法
 - 随机森林算法
 - AdaBoost, GBDT算法等
- 模型集成: 变量的集成和模型的集成
 - 基于同一数据源不同算法的集成
 - 基于不同数据源不同算法的集成(不同的数据类型对应适合的算法)
 - 基于数据源不同部分分配给不同算法之后的集成

模型应用

- 模型结果作为强变量, 再次使用传统算法(适用于比较保守的金融机构, 非常注重模型解释性)
- 单个模型的直接应用
- 模型组合: 交叉使用

数据观

大数据集成模型



数据观

3. 大数据风控技术应用

01 欺诈风险策略规则

02 风险评分

数据观

01. 欺诈风险策略规则

欺诈风险策略规则举例


- ▶ 同一手机在一段时间内多次申请贷款，存在欺诈嫌疑
- ▶ 同一手机在一段时间内在多家机构申请贷款，存在欺诈嫌疑
- ▶ 申请人在一段时间内更换过多个手机号或地址，存在欺诈嫌疑
- ▶ 申请人填写地址与实际居住地址差距非常远，存在欺诈嫌疑

数据观

02. 风险评分


- ▶ 评分模型是基于金融机构信贷违约数据样本专门建立的模型，针对性强，覆盖面广
- ▶ 风险评分主要基于个人最客观的行为偏好数据，利用机器学习和大数据技术，从几千个原始的弱变量中提取出能够有效识别好坏客户的强变量，再运用国际上流行的个人信用评分模式，以使模型具备有效性、稳定性和高预测能力
- ▶ 大数据下的风险评分，在保证数据真实、客观、全面的前提下，综合评估了客户的身份匹配数据、用户行为数据、收支等级数据、航旅行为数据、支付消费数据、社交行为数据等，以更加准确的评价个人的信用风险

评分参考因素



数据观

02. 风险评分应用策略



- 风险评分分值在300~1000分之间，分数越高代表信用风险越低，违约的可能性越小
- 不同的评分区间与信用风险等级对应如下：
 - [300,500] 高风险
 - [500,550] 中风险
 - [550,1000] 低风险