

前言：

[数据科学](#)越来越火了，网页是数据很大的一个来源。最近很多人问怎么抓网页数据，据我所知，常见的编程语言 (C++, java, python) 都可以实现抓网页数据，甚至很多统计\计算的语言 (R, Matlab) 都有可以实现和网站交互的包。本人试过用 java, python, R 抓网页，感觉语法各有差异，逻辑上是一样的。我准备用 python 来大概讲讲抓网页是什么概念，具体的内容要自己看[手册](#)或者 google 别人的博客，这里算是抛砖引玉了。水平有限，出现错误或者有更好的办法，欢迎讨论。

## 步骤一：熟悉Python的基本语法。

已经熟悉Python的直接跳到步骤二。

Python是门比较容易入门的编程语言，如何上手视编程基础而定。

(1) 如果有一定编程的基础，建议看 google's python class，链接<https://developers.google.com/edu/python/?hl=zh-CN&cs=1>

这个是一个为期两天的短期培训课程（当然，是两个全天），大概是七个视频，每个视频之后给编程作业，每个作业一个小时之内可以完成。这是我学习python的第二门课（第一门是codecademy的python，很早之前看的，很多内容都记不得了），当时每天看视频+编程作业一个多小时，六天弄完，效果还不错，用python写基本的程序没有问题。

(2) 如果是没有任何编程基础，建议看 coursera 上 Rice University 开的 An Introduction to Interactive Programming in Python。这门课我没有跟过，但是看 coursetalk 的评论反映非常好，地里也有同学评论([点这里](#))，课程链接：<https://www.coursera.org/course/interactivepython>。Udacity 上的 CS101 也是不错的选择，地里有相关的讨论帖([点这里](#))，而且这门课就叫做 build a search engine，会专门讲一些和网络相关的 module。其他学习资源还有 code school 和 codecademy，这些资源也是挺不错的，但是编程量太少，初学者还是系统的跟课、多练练手来打好基础吧。

当然，每个人的偏好不同，我推荐的不一定适合你。可以先看看这个帖子[【长期加分贴】介绍你上过的公开课](#)里面其他人是怎么说的，或者上[coursetalk.org](http://coursetalk.org)看看课程评论，再决定吧。

## 步骤二：学会如何与网站建立链接，得到网页数据。

写脚本与网站进行交互，要熟悉 python 和网页相关的几个 module (urllib, urllib2, httplib) 中的一个，知道一个即可，其他的都类似的。这三个是 python 提供的和网页交互的基本 module，还有其他的一些，比如：

mechanize和scrappy，我没有用过，可能有更好的性能，欢迎了解的来补充。基本的网页抓取，前面的三个module足矣。· 鏝磋□鋤或滑@lpoint 3 acres  
下面的代码演示如何用urllib2与google scholar进行交互，获得网页信息。

```
[python]view plaincopy
```

```
1. # 导入模块 urllib2
2. import urllib2
3. # 随便查询一篇文章，比如On random graph。对每一个查询google
4. # scholar都有一个url，这个url形成的规则是要自己分析的。
5. query = 'On+random+graph'
6. url = 'http://scholar.google.com/scholar?
hl=en&q=' + query + '&btnG=&as_sdt=1%2C5&as_sdt='
7. # 设置头文件。抓取有些的网页不需要专门设置头文件，但是这里如果不设置的话，
8. # google会认为是机器人不允许访问。另外访问有些网站还有设置Cookie，这个会相对复杂
一些，
9. # 这里暂时不提。关于怎么知道头文件该怎么写，一些插件可以看到你用的浏览器和网站交互
的
10. # 头文件（这种工具很多浏览器是自带的），我用的是firefox的firebug插件。
11. header = {'Host': 'scholar.google.com',
12. 'User-
Agent': 'Mozilla/5.0 (Windows NT 6.1; rv:26.0) Gecko/20100101 Firefox/26.0
',
13.
'Accept': 'text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8
',
14. 'Accept-Encoding': 'gzip, deflate',
15. 'Connection': 'keep-alive'}
16. # 建立连接请求，这时google的服务器返回页面信息给con这个变量，con是一个对象
17. req = urllib2.Request(url, headers = header)
18. con = urllib2.urlopen( req )
19. # 对con这个对象调用read()方法，返回的是html页面，也就是有html标签的纯文本
20. doc = con.read(). 鏝磋□鋤或滑@lpoint 3 acres
21. # 关闭连接。就像读完文件要关闭文件一样，如果不关闭有时可以、但有时会有问题，
22. # 所以作为一个守法的好公民，还是关闭连接好了。
```

```
23. con.close()
```

以上的代码就把在google scholar上查询On Random Graph的结果返回到doc这个变量中了，这个和你打开google scholar搜索On Random Graph，然后将网页右键保存的效果是一样的。

### 步骤三、解析网页

上面的步骤得到了网页的信息，但是包括了html标签，你要把这些标签去掉，然后从html文本中整理出有用的信息，

你需要解析这个网页。

解析网页的方法：

(1) 正则表达式。正则表达式很有用，熟悉它节省很多的时间，有时候清洗数据不用写脚本或者在数据库上查询，直接在notepad++上用正则表达式组合使用就行了。如何学习正则表达式建议看：正则表达式30分钟入门教程，链接：

<http://deerchao.net/tutorials/regex/regex.htm>

(2) BeautifulSoup模块。BeautifulSoup是一个很强大的模块，能把html文件解析成一个对象，这个对象是一棵树。我们都知道html文件是树状的，比如 body -> table -> tbody -> tr，对于tbody这个节点，有很多个tr的子节点。BeautifulSoup可以很方便的取到特定的节点，对单个节点也可以取它的sibling node。网上有很多相关的说明，这里不细说，只演示简单的代码：. Waral 錦氩  
□鏈爰洿氩构筠 ，

(3) 上面两种方法结合使用。

```
[python]view plaincopy
```

```
1. # 导入BeautifulSoup模块和re模块，re是python中正则表达式的模块
2. import BeautifulSoup.鐳權□璫哄漕-涓€浜-涓€攸培鎷
3. import re
4. # 生成一个soup对象，doc就是步骤二中提到的
5. soup = BeautifulSoup.BeautifulSoup(doc)
6. # 抓取论文标题，作者，简短描述，引用次数，版本数，引用它的文章列表的超链接。From 1point 3acres bbs
7. # 这里还用了一些正则表达式，不熟悉的先无知它好了。至于'class' : 'gs_rt'中
8. # 'gs_rt'是怎么来的，这个是分析html文件肉眼看出来的。上面提到的firebug插件
```

```

9. # 让这个变的很简单, 只要一点网页, 就可以知道对应的html 标签的位置和属性,
10. # 相当好用。
11. paper_name = soup.html.body.find('h3', {'class' : 'gs_rt'}).text
12. paper_name = re.sub(r'\
[.*\]', '', paper_name) # eliminate '[' tags like '[PDF]'
13. paper_author = soup.html.body.find('div', {'class' : 'gs_a'}).text
14. paper_desc = soup.html.body.find('div', {'class' : 'gs_rs'}).text
15. temp_str = soup.html.body.find('div', {'class' : 'gs_fl'}).text
16. temp_re = re.match(r'[A-Za-z\s]+(\d*) [A-Za-z\s]+(\d*)', temp_str)
17. citeTimes = temp_re.group(1).lstrip('0')
18. versionNum = temp_re.group(2)

19. if citeTimes == '':
20.     citeTimes = '0'-google lstrip('0')
21. if versionNum == '':
22.     versionNum = '0'
23.
citedPaper_href = soup.html.body.find('div', {'class' : 'gs_fl'}).a.attrs[
0][1]

```

这些都是我在一个分析citation network的项目的代码。顺便一提, 我从google scholar上抓取paper的信息以及引用列表的信息, 访问了大概1900次左右的时候给google block了, 导致这个片区的ip一时无法登陆google scholar。

. 鍍磋□鋤或滑@lstrip 3 acres

## 步骤四：存取数据

好不容易抓了数据, 现在只是存储在内存中, 必须保存起来才能利用。

(1) 最简单的方法之把数据写进txt文件中, Python中可以用如下代码实现: .

[python]view plaincopy

```

1. # 打开文件webdata.txt, 生成对象file, 这个文件可以是不存在的, 参数a表示往里面添加。
2. # 还有别的参数, 比如'r'只能读但不能写入, 'w'可以写入但是会删除原来的记录等等
3. file = open('webdata.txt', 'a'). more info on lstrip 3 acres.com

```

```

4.

line = paper_name + '#' + paper_author + '#' + paper_desc + '#' + citeTime
s + '\n'.

5. # 对象file的write方法将字符串line写入file中

6. file = file.write(line)

7. # 再一次的, 做个随手关闭文件的好青年

```

这样, 就把从网页上抓到并且解析了的数据存储到本地了, 是不是很简单?

(2) 当然, 你也可以不写入txt文件中, 而是直接连接数据库, python中的MySQLdb模块可以实现和MySQL数据库的交互, 把数据直接倒到数据库里面, 与MySQL数据库建立链接的逻辑和与网站服务器建立链接的逻辑差不多。如果之前有学习过数据库, 学习用MySQLdb模块实现和数据库的交互是很简单的; 如果没有, 则要借助在coursera\stanford openEdX平台上都有开设的Introduction to Database来系统学习, w3school用来参考或者当成手册。

Python能够链接数据库的前提是数据库是开着的, 我用的是 win7 + MySQL5.5, 数据库在本地。

```
[python]view plaincopy
```

```

1. %可以用cmd开启数据库, 启动命令是:

2. net start mysql55

3. %关闭命令是:

4. net stop mysql55

```

使用MySQLdb模块代码示例: -google 1point3acres

```
[python]view plaincopy
```

```

1. # 导入 MySQLdb模块

2. import MySQLdb

3. # 和服务建立链接, host是服务器ip, 我的MySQL数据库搭建在本机, 默认的是
127.0.0.1,

4. # 用户、密码、数据库名称对应着照输就行了, 默认的端口号是3306, charset是编码方式,

5. # 默认的是utf8(也有可能是gbk, 看安装的版本)。. Waral 錦氫□鏈爰洵湮氟构筠 ,

6.

conn = MySQLdb.connect(host='127.0.0.1', user='root', passwd='yourPassword
', db='dbname', port=3306, charset='utf8'). Waral 錦氫□鏈爰洵湮氟构筠 ,

```

```

7. # 建立cursor
8. cur = conn.cursor()-google 1point3acres
9. # 通过对象cur的execute()方法执行SQL语句
10.
cur.execute("select * from citeRelation where paperName = 'On Random Graph
'")
11. # fetchall()方法获得查询结果，返回的是一个list，可以直接这样查询：list[i][j]，
12. # i表示查询结果中的第i+1条record，j表示这条记录的第j+1个attribute(别忘了
python从0开始计数)
13. list = cur.fetchall()
14. # 也可以进行delete,drop,insert,update等操作，比如：
15.
sql = "update studentCourseRecord set fail = 1 where studentID = '%s' and
semesterID = '%s' and courseID = '%s'" %(studentID,course[0],course[1])
16. cur.execute(sql)
17. # 与查询不同的是，执行完delete,insert,update这些语句后必须执行下面的命令才能成
功更新数据库
18. conn.commit()
19. # 一如既往的，用完了之后记得关闭cursor，然后关闭链接
20. cur.close()
21. conn.close()

```

这样就实现了Python和数据库之间的交互。除了MySQL数据库外，python的PyGreSQL模块可以支持postgreSQL数据库，道理类似的。还有，如果你的网页里面包含了中文，设置编码格式会非常的麻烦，需要服务器、Python、数据库和数据库界面采用相同的编码格式才能不出现乱码，如果真的出现了中文乱码的问题，请相信，你不是一个人！！去google一下吧，成千上万的人碰到过这种问题。

关于编码的问题，附一篇我看到的博文<[python编码问题总结](http://www.xprogrammer.com/1258.html)>:

<http://www.xprogrammer.com/1258.html>

后记：

上面介绍了抓取网页数据的方法，抓取数据只是一小步，如何分析数据就是大学问了，欢迎讨论。

上面有什么地方讲不清楚的，欢迎交流。

**特别注意:.** From 1point 3acres bbs

大规模抓取网站会给网站的服务器带来很大的压力，尽量选择服务器相对轻松的时段（比如凌晨）。网站很多，不要拿一亩三分地来做试验。

Python的time模块的sleep()方法可以让程序暂停一段时间，比如time.sleep(1)让程序运行到这里的时候暂停1秒。适时地暂停可以缓解服务器的压力，也可以保护自己的硬盘，正好码久了睡个觉，或者去趟gym，结果就出来了